

Predicting Direct Object Omission

A Quantitative Approach to Direct Object Realisation Patterns
in Contemporary Peninsular Spanish

Philippa Adolf
Universität Wien

Alpes 6 – Kandersteg – 27.01.2026

Introducción

Motivación: ¿Por qué la omisión del objeto directo?

Trabajo actual del proyecto y experiencia previa

- ▶ Subproyecto del SFB → doblado clítico (DC) y **objetos nulos (ON)**
 - ▶ mantener continuidad con el proyecto es razonable
 - ▶ hay muy poco trabajo empírico sobre los ON en el español peninsular

Objetivo

- ▶ ofrecer una descripción basada en datos que integre la omisión de OD en el panorama general de la realización del OD en español

¿Qué es la omisión de OD?

S1: ¿Ha habido fanfics?

S2: Ya. Sí.

S1: ¿**Has leído**?

S2: No he leído nada, pero sí, (CQLPLQ323)

Preguntas de Investigación

Preguntas de investigación

¿Cuáles son **los predictores (lingüísticos) de la omisión del OD** en el español peninsular?

- 1 ¿Cuáles son las **propiedades sintácticas, semánticas y discursivas** de los OD omitidos?
- 2 ¿Pueden los **factores léxicos y los frames semánticos** predecir la omisión del OD?

¿Está **la omisión de OD** condicionada principalmente por la **licenciación estructural** (p. ej., animacidad, definitud) o por el **grado de entrenchment**?

¿Cómo se integra **la omisión de OD** en el **paradigma general de realización del OD** en español (junto a otras opciones de realización)?

Métodos

Metodología: diseño de métodos mixtos

Experimentos

- ▶ entorno lingüístico controlado
- ▶ evaluación de aceptabilidad y procesamiento en línea
- ▶ análisis de variación inter- e intra-hablante
- ▶ abordar relaciones causales

Estudio de corpus a gran escala

- ▶ datos naturales (o naturalistas)
- ▶ análisis exploratorios para identificar predictores
- ▶ información sobre frecuencia y productividad verbal
- ▶ información sobre propiedades discursivas de los ON

Experimentos

Eye tracking: procesamiento en línea

Clara: Oye, ¿está todo listo para la reunión hoy?

Sergio: Una cosa, ¿llevaste un extintor a la sala de conferencias?

Clara: Sí, pues llevé uno ya esta mañana y lo coloqué junto a la puerta.

Sergio: Perfecto, todo esto de las normas de seguridad me tiene bastante nerviosa.

Clara: No te preocupes, seguro que todo sale fenomenal.

Sergio: Eso espero, gracias.

Eye tracking: procesamiento en línea

Clara: Oye, ¿está todo listo para la reunión hoy?

Sergio: Una cosa ¿llevaste el extintor que pidió Simón para la sala de conferencias?

Clara: Sí, pu 38 49 é 41 45 la mañana y lo coloqué junto a la puerta.

Sergio: Perfecto, todo esto de las normas de seguridad me tiene bastante nerviosa.

Clara: No te preocupes, seguro que todo sale fenomenal.

Sergio: Eso espero, gracias.

ATJ (experimentos de aceptabilidad)

Dos amigos, Diego y Enrique, se encontraron. Enrique le había pedido un perfume a Diego.


Diego trajo el perfume y después Enrique vació en el desagüe.

(nada natural)

(muy natural)

Resultados (piloto)

Accusative Clitic Doubling – Peninsular Spanish (n=47)



Estudio de Corpus - Compilando un corpus propio

Objetivo general del estudio de corpus

Analizar patrones de realización del OD en español peninsular contemporáneo de forma verb-based.

- ▶ Realización del OD
 - ▶ OD explícitos
 - ▶ Doblado clítico (DC)
 - ▶ Marcado diferencial de objeto (DOM)
 - ▶ **Omisión del OD**
- ▶ Influencia de los **verbos**
- ▶ Entornos sintácticos
- ▶ Estructura discursiva

→ target structure: **sintagmas transitivos**

Compilación de ES-PEN-POD

selección de datos**sampling y adquisición****ASR****anotación discursiva****compilación y extracción****codificación asistida**

Los datos ideales: criterios

Un estudio de corpus solo es informativo si los datos son **suficientemente naturales y representativos**

► **Modalidad:**

- lengua hablada, dialogada
- producción espontánea o semi-espontánea
- registro coloquial

► **Contexto de producción:**

- mínima intervención editorial
- formatos largos con discurso continuo

► **Disponibilidad de metadatos:**


- control de edad, variedad, género

→ **Youtube Podcasts**

Estrategias de sampling

Tamaño del corpus


- ▶ fenómeno de baja frecuencia (1–3%)
- ▶ objetivo: varios cientos de instancias de OD omitido
- ▶ tamaño final previsto: ~1 millón de palabras
- ▶ sampling acumulativo hasta alcanzar potencia estadística suficiente



Estratificación y balance discursivos del corpus

Distribución de hablantes:

- ▶ sobre-representación inevitable de hosts recurrentes
- ▶ mitigación mediante el número de canales
- ▶ distribución equilibrada de género
- ▶ rango de edad entre 20–70 años



70%

conversaciones informales en grupo



30%

entrevistas semi-estructuradas

Adquisición de datos

Para cada episodio seleccionado se almacenan:

- ▶ nombre del canal
- ▶ URL; ID del episodio
- ▶ fecha de subida
- ▶ fragmento de la descripción
- ▶ título del episodio
- ▶ metadatos sobre los hablantes

Extracción de audio con YT-DLP (extractor determinista):

- ▶ resuelve URLs de medios de la plataforma
- ▶ selecciona el stream de audio
- ▶ descarga y post-procesa (vía `ffmpeg`)
- ▶ se extraen 60min por episodio

Transcripción de los audios con Whisper (ASR)

Propiedades clave:

- ▶ software open source (licencia MIT)
- ▶ ejecución local y offline (una vez instalado)
- ▶ generalmente buen rendimiento

Elección del modelo medium de **WHISPER**

- ▶ mayor estabilidad en hardware limitado
- ▶ buen equilibrio entre calidad y coste computacional

→ mostrar el código

Control de calidad del ASR

Objetivo: estimar la calidad del ASR **solo** en **contextos relevantes**

Principios:

- ▶ comprobación únicamente en estructuras candidatas
- ▶ verificación manual de **un episodio por podcast** (detección de diferencias entre canales)
- ▶ **sin** limpieza global de transcripciones

Diseño de anotación QC:

- ▶ 100 candidatos por episodio: verbos en (posibles) construcciones transitivas
- ▶ por candidato: ¿verbo y estado de OD correcto?
→ (sí/no) + tipo de error (si aplica)

Errores críticos

Errores que afectarían directamente a la codificación del OD:

- ▶ **sustitución de clíticos:** confusión *lo/la/le/se*; clítico eliminado o insertado
- ▶ **error en forma verbal:** afecta a la identificación de construcción transitiva
- ▶ **error de preposición:** relevante para DOM (p. ej. *a*)

Resultado de lo episodios evaluados:

- ▶ proporción de candidatos correctamente transcritos: **98%–100%**
- ▶ solo una **pequeña fracción** de errores requiere corrección para decidir el estatus del OD
- ▶ y una fracción aún menor **cambia** la clasificación del OD

Errores observados (en general)

En general: asociados a baja calidad, solapamiento o habla muy rápida

Ambigüedad de forma verbal (tiempo/persona)

- ▶ típicamente en ausencia de señales prosódicas claras
- ▶ *modificó* → *modifico*
- ▶ *habló* → *hablo*

Omisión o sustitución de auxiliar

- ▶ *la encontrado* → *la he encontrado*
- ▶ *perdido* → *ha perdido*

Reconocimiento erróneo de lema (raro)

- ▶ *lo conví* → *lo vi*
- ▶ *me digo* → *me dedico*

Falsos errores: variación coloquial preservada

Durante el QC, algunas formas aparentemente “incorrectas” resultaron ser **uso real**:

- ▶ creatividad/coloquialidad: *parotínamente, volviar*
- ▶ construcciones no canónicas: *pégale esto a ellos*
- ▶ nombres propios variables: *louis bouton, tu pack*
- ▶ anglicismos: *sock, yes music*

Implicación: **Whisper preserva bien variación coloquial y rasgos idiolectales.**

→ Sketch Engine

Anotación discursiva de las transcripciones

- ▶ Anotación **inline** y en **texto plano** (en .txt; sin XML)
- ▶ Todos los marcadores usan un **prefijo único** para evitar colisiones con tokens naturales
- ▶ Los símbolos se diseñan para ser:
 - ▶ legibles para humanos
 - ▶ fáciles de buscar
 - ▶ eliminables de forma trivial en el preprocesamiento
- ▶ Cada transcripción anotada se va a subir a **Sketch Engine**

→ ejemplo anotación

Selección de lemas verbales – enfoque general

Principios generales

- ▶ 100-150 lemas verbales
- ▶ La selección de lemas verbales sigue un **enfoque empírico y basado en datos**, sin recurrir a listas predefinidas de la literatura.
- ▶ La **transitividad** no se concibe como una propiedad binaria del verbo, sino **gradual**.
- ▶ Solo se excluyen *a priori* verbos claramente intransitivos (p. ej. *morir*, *ir*, *caer*); se conservan verbos alternantes y ditransitivos.

Criterios teóricos y operativos de selección

Clases orientativas: (Martínez-García, Rinke, and Kerezova 2025)

- ▶ consumo / creación (*comer, hacer*)
- ▶ comunicación / transferencia (*decir, dar*)
- ▶ percepción / cognición (*ver, entender*)
- ▶ manipulación / afectación (*romper, ayudar*)
- ▶ movimiento / contacto (*llevar, poner*)
- ▶ predicados evaluativos con objeto proposicional (*creer, pensar*)

Criterios de frecuencia:

- ▶ se excluyen lemas con comportamiento casi categórico intransitivo (p. ej. 90–100% de usos)
- ▶ se excluyen lemas con poca dispersión en el corpus
- ▶ se van a escoger los lemas más frecuentes

Ya que no fui famarito, **me podrían haber dado**, ¿no crees?. (CQLPLQ323)

Ya, amor. En plan, **no sé**. Es que estaba yo delulu, perdía. Bueno, hay una cosa que .. (CQLPLQ323)

¿Pero qué es sipeo? Yo con Paul. Ah, es que **no entiendo, no lo entiendo**, lo siento. (CQLPLQ323)

Es que el tríceps yo no tengo, **pero Vicky tiene**. Sí, pero ya lo he enseñado mucho y no quiero (QCEEC710)

a ver qué he hecho ahora. **No lo sé**, la verdad. Entonces, es gracioso, Es decir, ¿tú qué tipo de infancia tuviste? Pues, **no sé**, yo tuve una infancia bastante normal (QCTWP338)

¡Muchas Gracias!

¿Preguntas?

¿Sugerencias para podcasts? (necesito uno más)

Referencias I



Campos, Héctor (1986). “Indefinite Object Drop”. In: *Linguistic Inquiry* 17.2, pp. 354–359.



Clements, J. Clancy (2006). “Null Direct Objects in Spanish”. In: *Functional Approaches to Spanish Syntax*. Ed. by J. Clancy Clements and Jiyoung Yoon. London: Palgrave Macmillan UK, pp. 134–150. ISBN: 978-1-349-54428-8 978-0-230-52268-8. DOI: 10.1057/9780230522688_6. URL: http://link.springer.com/10.1057/9780230522688_6 (visited on 06/09/2024).



Cyrino, Sonia (2017). “The Null Object in Romania Nova”. In: *The Morphosyntax of Portuguese and Spanish in Latin America*. Ed. by Mary A. Kato and Francisco Ordonez. Oxford Studies in Comparative Syntax. Oxford Academic.



— (2019). “Indefinite Null Objects in Spanish and Brazilian Portuguese”. In: *Caderno de Squibs Temas em estudos formais da linguagem* 5.2, pp. 14–26.



Glass, Lelia (Mar. 2022). “English Verbs Can Omit Their Objects When They Describe Routines”. In: *English Language and Linguistics* 26.1, pp. 49–73. ISSN: 1360-6743, 1469-4379. DOI: 10.1017/S1360674321000022. URL: https://www.cambridge.org/core/product/identifier/S1360674321000022/type/journal_article (visited on 07/04/2024).

Referencias II



Goldberg, Adele E. (Feb. 28, 2005). “Argument Realization: The Role of Constructions, Lexical Semantics and Discourse Factors”. In: *Constructional Approaches to Language*. Ed. by Jan-Ola Östman and Mirjam Fried. Vol. 3. Amsterdam: John Benjamins Publishing Company, pp. 17–43. ISBN: 978-90-272-1823-0 978-1-58811-579-9 978-90-272-1826-1 978-90-272-9470-8. DOI: 10.1075/cal.3.03gol. URL: <https://benjamins.com/catalog/cal.3.03gol> (visited on 02/26/2025).



Huang, James (1984). “On the Distribution and Reference of Empty Pronouns”. In: *Linguistic Inquiry* 15.4, pp. 531–574. ISSN: 00243892, 15309150. JSTOR: 4178404. URL: <http://www.jstor.org/stable/4178404> (visited on 09/08/2025).



Landa, Alazne (1995). “Conditions on Null Objects in Basque Spanish and Their Relation to Leismo and Clitic Doubling”. ProQuest Dissertations & Theses.



Martínez-García, Carlos, Esther Rinke, and Nelli Kerezova (Feb. 19, 2025). “Indefinite Object Drop Is Lexically Constrained”. In: *Glossa: a journal of general linguistics* 10.1. ISSN: 2397-1835. DOI: 10.16995/glossa.17889. URL: <https://www.glossa-journal.org/article/id/17889/> (visited on 03/04/2025).

Referencias III



Raposo, Eduardo (Dec. 31, 1986). “On the Null Object in European Portuguese”. In: *Studies in Romance Linguistics*. Ed. by Osvaldo Jaeggli and Carmen Silva-Corvalán. Berlin, Boston: De Gruyter, pp. 373–390. ISBN: 978-3-11-087851-6. DOI: 10.1515/9783110878516-024. URL: <https://www.degruyter.com/document/doi/10.1515/9783110878516-024/html> (visited on 06/09/2024).




Reig Alamillo, Asela (Nov. 2016). “Propositional Clitic Omission in Spanish and Lack of Knowledge”. In: *Journal of Pragmatics* 105, pp. 1–17. ISSN: 03782166. DOI: 10.1016/j.pragma.2016.09.009. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0378216616304921> (visited on 04/04/2025).




Schwenter, Scott (2006). “Null Objects across South America”. In: *Selected Proceedings of the 8th Hispanic Linguistics Symposium*. MA: Cascadilla Proceedings Project. Ed. by Timothy Face and Carol Klee, pp. 23–36.

Apéndice

Visión general del proyecto





Background

ON con nombres de masa y plurales escuetos

(1) a.

*¿Juan traerá **cerveza** a la fiesta? Su novia*
 Juan bring-FUT.3SG beer-ACC to the.F party his/her girlfriend
me dijo que traería.
 1SG.DAT say-PST.3SG that bring-COND.3SG

‘Is Juan going to bring beer to the party? — His girlfriend told me that he is (bringing beer).’

b.

*¿Pepe necesita **gafas**? Es obvio que necesita.*
 Pepe need-PRS.3SG glasses-ACC be-PRS.3SG obvious that need-PRS.3SG

‘Does Pepe need glasses? — He obviously does (need glasses).’

(Campos 1986)

ON en coordinación

(2) a.

Pedro arreglaba las bicicletas y Rosa vendía
 Pedro fix-IPFV.PST.3SG the.F.PL bicycle-ACC.PL and Rosa sell-IPFV.PST.3SG
a sus amigos.
 to POSS.3SG friend-DAT.PL

‘Pedro fixed the bikes up and Rosa sold them to her friends.’

b.

Pedro les leía libros a los niños
 Pedro 3PL.DAT read-IPFV.PST.3SG book-ACC.PL to the.M.PL child-DAT.PL
y María también leía.
 and Maria also read-IPFV.PST.3SG

‘Pedro read books to the children and María did as well.’

(Cyrino 2019)

ON en pares pregunta–respuesta

(3) a.

Traigo un pañuelo. - *¿Me das?*
 bring-PRS.1SG a handkerchief-ACC 1SG.DAT give-PRS.2SG

‘I’m bringing a handkerchief. — Can you give it to me?’

b.

¿Compraste pañuelos? - *Sí, compré.*
 buy-PST.2SG handkerchief-ACC.PL yes buy-PST.1SG

‘Did you buy handkerchiefs? — Yes, I did (buy some).’

(Martínez-García, Rinke, and Kerezova 2025)

Objetos nulos a través de lenguas y variedades del español

Objetos nulos en perspectiva tipológica

- ▶ **Lenguas de Asia oriental** (p. ej., chino, japonés): caída radical del objeto
- ▶ **Portugués (brasileño)**: objetos nulos amplios, elipsis de SV
- ▶ **Inglés**: omisión condicionada léxicamente

(Huang 1984, Goldberg 2005, Glass 2022, Raposo 1986, Cyrino 2017, et al.)

Variedades (de contacto) del español

- ▶ Español del País Vasco
- ▶ Variedades americanas
 - ▶ andinas
 - ▶ paraguaya
 - ▶ quiteña
 - ▶ rioplatense

(Schwenter 2006, Clements 2006, Landa 1995, Reig Alamillo 2016; *et al.*)

Español peninsular:


→ ON parciales/restringidos; restricciones estrictas

ON en el español peninsular: ¿qué creemos saber?

- ▶ Restricciones semánticas y discursivas:
 - ▶ Los **ON** se ven favorecidos con referentes **indefinidos, genéricos e inanimados**
 - ▶ Los **ON** solo son posibles con referentes altamente **salientes o recuperables**
- ▶ Restricciones sintácticas:
 - ▶ sensibilidad a islas
 - ▶ ausencia de VP elipsis
- ▶ ?Restricciones léxicas:
 - ▶ la disponibilidad de ON indefinidos parece depender del verbo
- ▶ ?Interacción con otras opciones de realización del OD
 - ▶ con el marcado diferencial de objeto (DOM)
 - ▶ con el doblado clítico (DC)

Teoría y Terminología

Tipología (mía) de los ON y fenómenos relacionados



Puntuación en Whisper

La puntuación se infiere probabilísticamente a partir de correlatos prosódicos:

- ▶ duración de pausas
- ▶ reinicio de tono / contornos entonativos
- ▶ alargamiento final
- ▶ cambios de ritmo
- ▶ caída de energía

Densidad de puntuación depende del estilo:

- ▶ **más puntuación:** habla lenta, reflexiva; turnos tipo entrevista/explicación
- ▶ **mínima puntuación:** conversación rápida; solapamientos; pocas pausas

Diseños experimentales

Eye-tracking durante la lectura (dos partes)

- ▶ 2×2 : realización (overt vs. covert) $\times$ propiedad del objeto (p. ej. animacidad/definitud)
- ▶ medidas: duraciones de fijación de primera pasada y totales en AOIs, regresiones

Expectativas:

- ▶ retraso global en el procesamiento cuando el OD se omite
- ▶ menor coste de procesamiento para referentes indefinidos e inanimados que para referentes definidos y animados

Tarea de juicios de aceptabilidad

- ▶ $2 \times 2 \times 3$: realización (overt vs. covert) $\times$ tipo de objeto antecedente (plural escueto/nombre de masa vs. SN indefinido) $\times$ clase verbal
- ▶ escala Likert de 7 puntos; en línea vía JATOS/JsPsych

Expectativas:

- ▶ efectos de clase verbal y de marco semántico (p. ej. posesión/consumo > movimiento > cognición/emoción)
- ▶ aceptabilidad de ON con plurales escuetos/nombres de masa > ON indefinidos

Coding of Data

Category	Variables
Lexical properties	Lemma, tense, aspect, person; phasal adverbs (<i>ya, aún</i> , etc.)
Argument structure	Presence/absence of subject , direct object (DO), indirect object (IO)
Object properties	Animacy, definiteness, specificity, DOM , DO antecedent type
Subject properties	Animacy, definiteness, specificity
Discourse features	Continuity of referent (from prior context), distance
Syntactic context	Subordination/coordination, clitic doubling
Semantic frames	via Spanish FrameNet
Frequency/Usage	Token/type frequency, dispersion, surprisal, pointwise mutual information (PMI)